

# RAPPORT TECHNIQUE - POC SYSTEME RAG POUR LA RECOMMANDATION D'EVENEMENTS CULTURELS

## 1. Introduction

### Contexte et Objectifs

Puls-Events, plateforme innovante dans la gestion d'événements culturels, avons initié un Proof of Concept (POC) pour évaluer la faisabilité d'un chatbot intelligent capable de fournir des recommandations personnalisées d'événements culturels.


Ce système s'appuie sur une architecture RAG (Retrieval-Augmented Generation) pour augmenter les réponses avec des données précises issues de la base Open Agenda.

#### Périmètre du POC :

- Région : Nouvelle-Aquitaine
- Période : Événements de moins d'un an
- Volume de données : ~10 000 événements
- Durée : POC sur 2 semaines

## 2. Architecture du Système

### 2.1 Workflow Global



### 2.2 Composants Techniques

#### 2.2.1 Collecte de Données (`data_importer.py`)

- **Source** : API Open Agenda publique
- **Filtres appliqués** :
  - Région Nouvelle-Aquitaine
  - Événements datant d'au plus un an

- Pagination intelligente par plages de 3 mois
- **Prétraitement** :
  - Nettoyage HTML des descriptions
  - Formatage des dates en français
  - Structuration des métadonnées

### 2.2.2 Vectorisation (`faiss_vectorizer.py`)

- **Modèle d'embedding** : `sentence-transformers/all-MiniLM-L6-v2`
- **Champs vectorisés** : titre, description, adresse, dates
- **Optimisations** : traitement par batch de 500 documents

### 2.2.3 Base Vectorielle FAISS

- **Type d'index** : Index FlatIP (similarité cosinus)
- **Dimension** : 384 (spécifique au modèle choisi)
- **Métadonnées** : conservation de tous les champs événement

### 2.2.4 Système RAG (`chatbot.py`)

- **LLM** : Mistral-medium via API
- **Retriever** : FAISS avec k=5
- **Prompt engineering** : Template spécialisé événements culturels

## 3. Choix Techniques Détaillés

### 3.1 Modèle d'Embedding : all-MiniLM-L6-v2

Évaluation Comparative :

| Modèle                  | Vitesse        | Qualité       | Param | Adaptation FR |
|-------------------------|----------------|---------------|-------|---------------|
| all-MiniLM-L6-v2        | ✓ 1x           | ✓ Adéquate    | 22.7M | ✓ Suffisante  |
| sentence-camembert-base | ✗ 4x plus lent | ✓ Équivalente | 110M  | ✓ Meilleure   |

Justification du choix :

- **Performance** : Faible gain qualitatif perceptible avec le modèle français
- **Efficacité** : Temps de traitement 4x inférieur
- **Pragmatisme** : Le modèle multilingue suffit pour ce cas d'usage

### 3.2 Modèle LLM : Mistral-medium

Analyse des alternatives :

| Modèle         | Qualité      | Coût     | Context Window | FR         |
|----------------|--------------|----------|----------------|------------|
| mistral-tiny   | ✗ Limitée    | ✓ Faible | 32k            | ✓ Correct  |
| mistral-small  | ✓ Bonne      | ✓ Modéré | 32k            | ✓ Bon      |
| mistral-medium | ✓ Excellente | ? Élevé  | 32k            | ✓ Très bon |

| Modèle        | Qualité   | Coût         | Context Window | FR        |
|---------------|-----------|--------------|----------------|-----------|
| mistral-large | ✓ Optimal | ✗ Très élevé | 32k            | ✓ Optimal |

#### Justification :

- **Qualité de génération** nécessaire pour les recommandations culturelles
- **Capacités en français** avancées adaptées au domaine
- **Context window** suffisant pour les documents événementiels

### 3.3 Base Vectorielle : FAISS

#### Avantages constatés :

- Recherche similitude très rapide (<100ms)
- Intégration native avec LangChain
- Support CPU satisfaisant pour le POC
- Persistance disque simple

## 4. Implémentation

### 4.1 Pipeline de Données

#### 4.1.1 Collecte Optimisée

python

```
# Stratégie de pagination par plages temporelles
date_ranges = []
for i in range(16): # 4 ans = 16 trimestres
    range_start = start_date + timedelta(days=90 * i)
    # Gestion optimisée des limites API
```

#### 4.1.2 Vectorisation

python

```
def get_embedding_text(doc):
    return "\n".join([
        doc.get("titre", ""),
        doc.get("description", ""),
        "Adresse : " + doc.get("adresse", ""),
        "Dates : " + ", ".join(doc.get("dates_affichage", [])),
    ])
```

### 4.2 Système RAG

#### 4.2.1 Prompt Engineering

python

```
prompt_template = """Tu es un assistant spécialisé dans les événements en
Nouvelle-Aquitaine.
Utilise les informations suivantes pour répondre à la question. Si tu ne sais
```

pas, dis que tu ne sais pas.

Informations disponibles:  
{context}

Question: {question}

Réponse utile:""

#### 4.2.2 Configuration du Retriever

python

```
retriever = vectorstore.as_retriever(search_kwargs={"k": 5})
```

## 5. Résultats et Évaluation

### 5.1 Résultats Techniques

#### Performances :

- Temps de réponse moyen : 2-4 secondes
- Précision des recherches : élevée sur requêtes simples
- Stabilité : 100% durant la période de test

#### Couverture fonctionnelle :

- ☒ Recherche par lieu ("Bordeaux", "Pau")
- ☒ Recherche par type ("concert", "exposition")
- ☒ Recherche temporelle basique
- ? Recherche sémantique avancée

### 5.2 Limitations Identifiées

#### 5.2.1 Limitations Techniques

- **Absence de métriques quantitatives** : Pas de jeu de test annoté
- **k=5 potentiellement sous-optimal** : Risque de bruit dans les résultats
- **Gestion temporelle limitée** : Pas de compréhension des dates relatives

#### 5.2.2 Limitations Fonctionnelles

- Pas d'historique de conversation
- Interface en ligne de commande uniquement
- Pas de gestion des préférences utilisateur

### 5.3 Tests Unitaires

#### Validation des données :

python

```
# Vérification du périmètre géographique
def test_region_filter():
    assert all(doc['location_region'] == 'Nouvelle-Aquitaine')

# Vérification de la période
def test_date_recency():
    assert all(event_date >= CUTOFF_DATE)
```

## **6. Recommandations pour la Version Finale**

### **6.1 Recommandations Prioritaires**

#### **? Validation POC → Production**

##### **1. Maintenir l'architecture technique actuelle**

- Modèle embedding : all-MiniLM-L6-v2
- Base vectorielle : FAISS
- Framework : LangChain

##### **2. Ajuster le paramètre k=3**

- Meilleur ratio signal/bruit
- Réduction des coûts API
- Réponses plus focalisées

##### **3. Abandonner les modèles français spécialisés**

- ROI insuffisant pour ce cas d'usage
- Surcharge computationnelle importante

#### **? Développements à Planifier**

##### **4. Créer un jeu de test annoté (20-30 questions)**

- Métriques : ROUGE-L, précision sémantique
- Couvrir différents types de requêtes
- Évaluation continue des performances

##### **5. Améliorer la gestion temporelle**


- Compréhension des dates relatives
- Filtrage par période dans les requêtes
- Gestion des événements récurrents

##### **6. Développer une interface utilisateur**

- Application web simple (Streamlit)
- Historique des conversations
- Feedback utilisateur

## 6.2 Architecture Cible Production

text



## 6.3 Plan de Montée en Charge

### Phase 1 (3 mois) :

- Jeu de test annoté et métriques
- Interface web basique
- Ajustement paramètres RAG

### Phase 2 (6 mois) :

- Extension à d'autres régions
- Système de recommandation personnalisé
- Optimisation des coûts infrastructure

### Phase 3 (12 mois) :

- Intégration avec le système existant Puls-Events
- Features avancées (alertes, préférences)

## 7. Conclusion

Le POC a démontré la faisabilité technique d'un système RAG pour la recommandation d'événements culturels. L'architecture choisie offre un excellent compromis entre performance, coût et maintenabilité.

### Points forts :

- Pipeline de données robuste
- Choix techniques pragmatiques et efficaces
- Intégration réussie des composants
- Potentiel d'extension important

### Prochaines étapes immédiates :

1. Présentation aux équipes produit/marketing
2. Validation du concept business
3. Planification du développement version finale

Le système est prêt pour une démonstration live et présente des perspectives concrètes pour un déploiement en production.